EDA visual del dataset

Proyecto: Precio de propiedades residenciales en venta

Estudiante: García, Lucía
Pre-entrega: EDA visual del dataset del proyecto
Octubre de 2026

Resumen del dataset

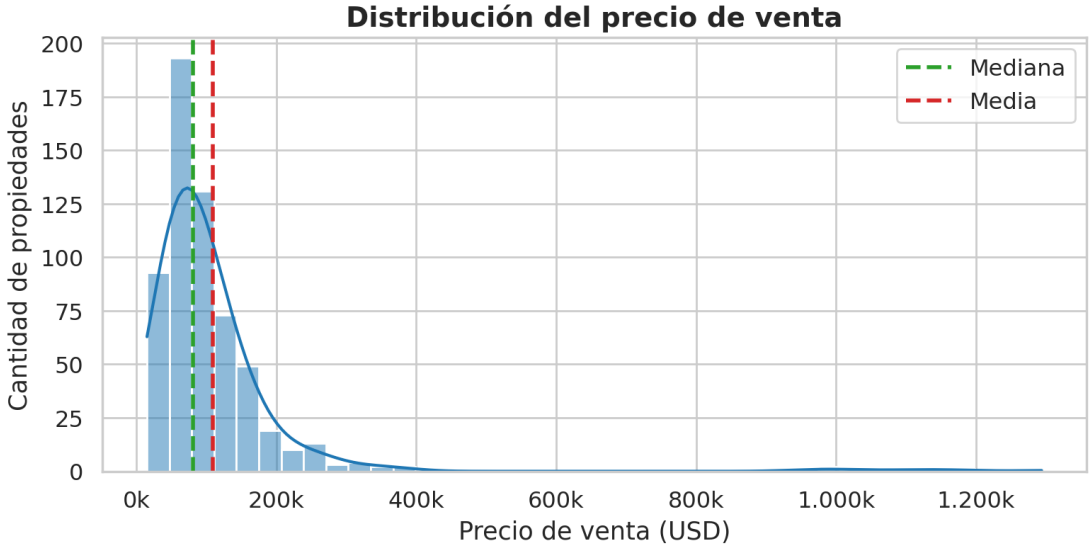
El dataset reúne **600 propiedades residenciales en venta** de una ciudad intermedia, con **9 columnas**: identificador, barrio (5 zonas), tipo de propiedad (departamento, casa o PH), superficie en m², cantidad de ambientes, antigüedad en años, distancia al centro en km y precio de venta en USD. Los datos ya fueron limpiados en el módulo anterior (sin valores nulos ni duplicados). El objetivo del proyecto es **predecir el precio de venta**, por lo que este EDA busca entender cómo se distribuye el precio y qué variables parecen explicarlo.

Variable	Tipo	Descripción
barrio	Categórica	Zona de la ciudad (5 categorías)
tipo	Categórica	Departamento, Casa o PH
superficie_m2	Numérica	Superficie cubierta + descubierta (m²)
ambientes	Numérica	Cantidad de ambientes (1 a 8)
antiguedad_anios	Numérica	Años desde la construcción
distancia_centro_km	Numérica	Distancia al centro (km)
precio_usd	Numérica (objetivo)	Precio de venta (USD)

Todos los gráficos usan el mismo estilo visual (**sns.set_theme(style='whitegrid')**). Se analiza primero cada variable por separado (para detectar outliers) y recién después se estudian las relaciones.

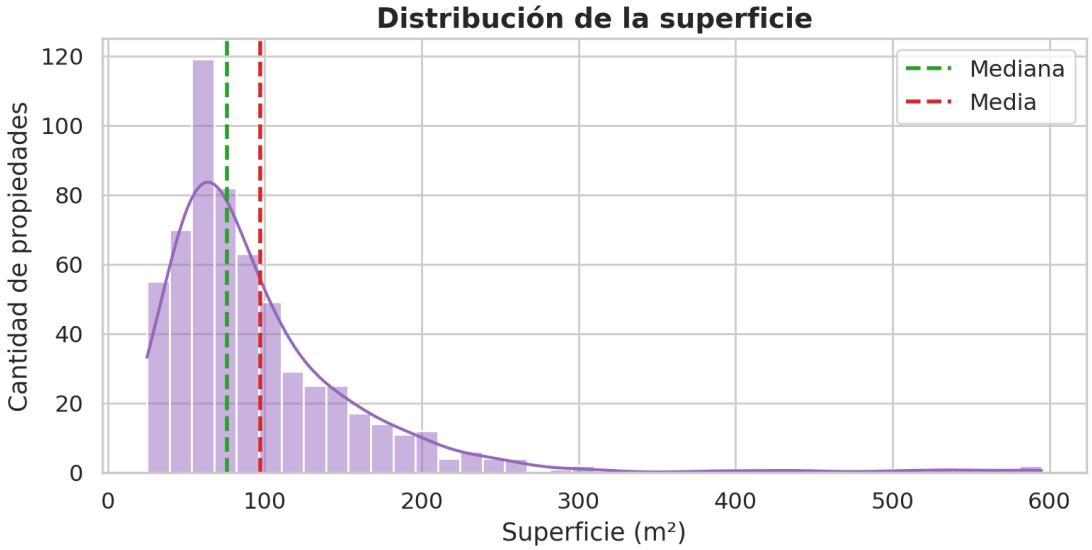
1. Análisis univariado

Gráfico 1 · Distribución del precio de venta



Qué observamos: El precio tiene un **fuerte sesgo a la derecha** (asimetría = 6,2): la mediana es USD 81.000 y la media USD 109.198, porque unas pocas propiedades muy caras la empujan hacia arriba. Hay **35 outliers (5,8 %)** por encima de USD 223.438 según el criterio 1,5×IQR. **Conclusión:** conviene usar la mediana como valor típico y evaluar una transformación logarítmica del precio antes de modelar.

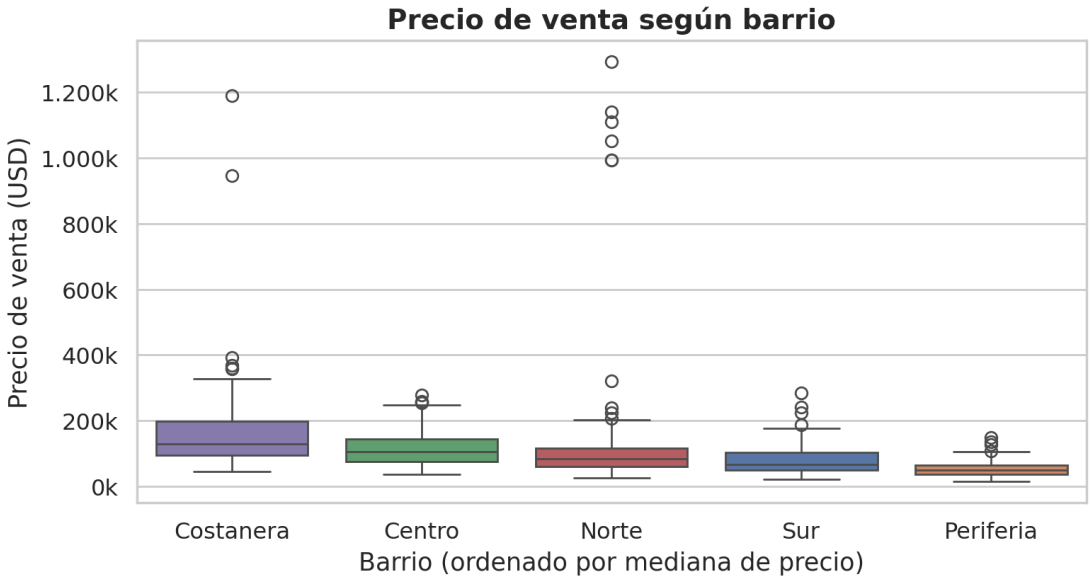
Gráfico 2 · Distribución de la superficie



Qué observamos: La superficie también es asimétrica a la derecha (asimetría = 3,3): la mitad de las propiedades mide menos de 76 m² y el 50 % central está entre 56 y 116 m². La media (97 m²) supera a la mediana por una cola de casas grandes que llega hasta 595 m². **Conclusión:** la variable mezcla tipos de propiedad de tamaños muy distintos, algo que revisaremos en el gráfico 4.

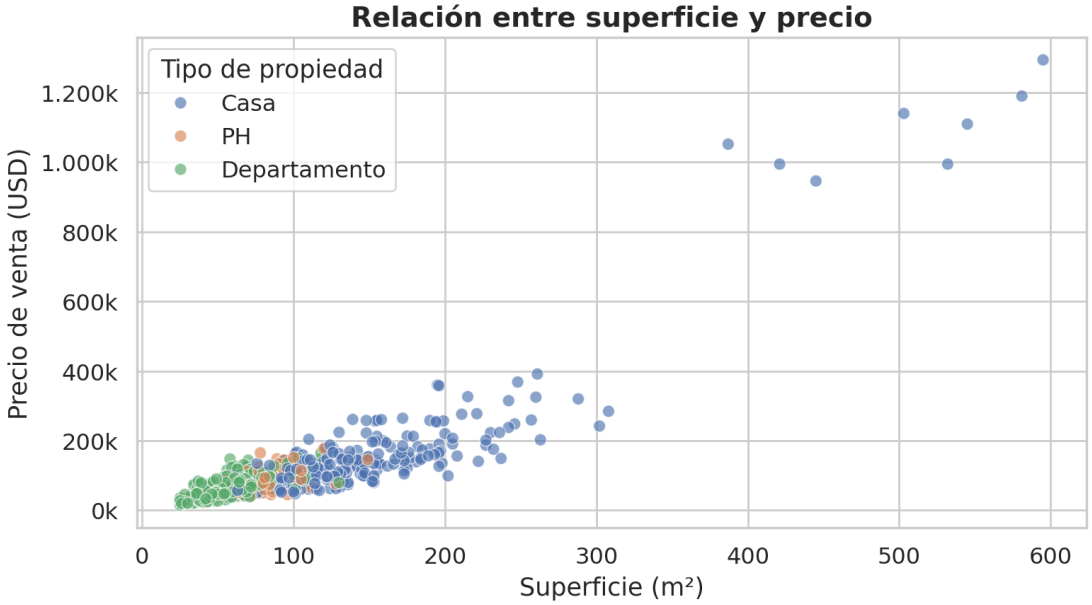
2. Análisis bivariado y multivariado

Gráfico 3 · Precio de venta según barrio



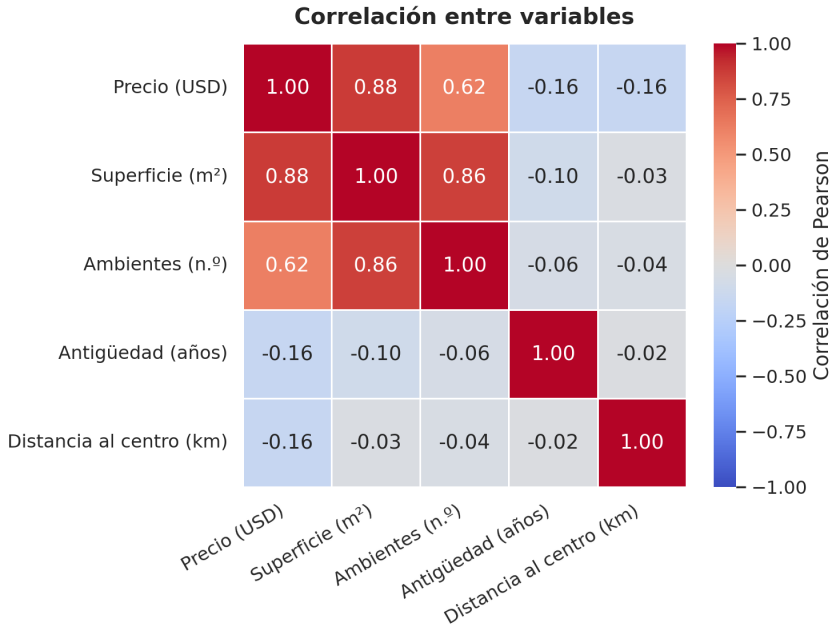
Qué observamos: El precio mediano baja de **Costanera** (USD 128.000) a **Periferia** (USD 48.500), unas 2,6 veces menos. La dispersión también cambia: el IQR en Costanera (USD 104.375) es mucho mayor que en Periferia (USD 28.500). Casi todos los outliers (18 de 35) están en Costanera. **Conclusión:** el barrio es una variable clave para el precio y la heterogeneidad de la zona premium justifica analizarla por separado.

Gráfico 4 · Relación entre superficie y precio



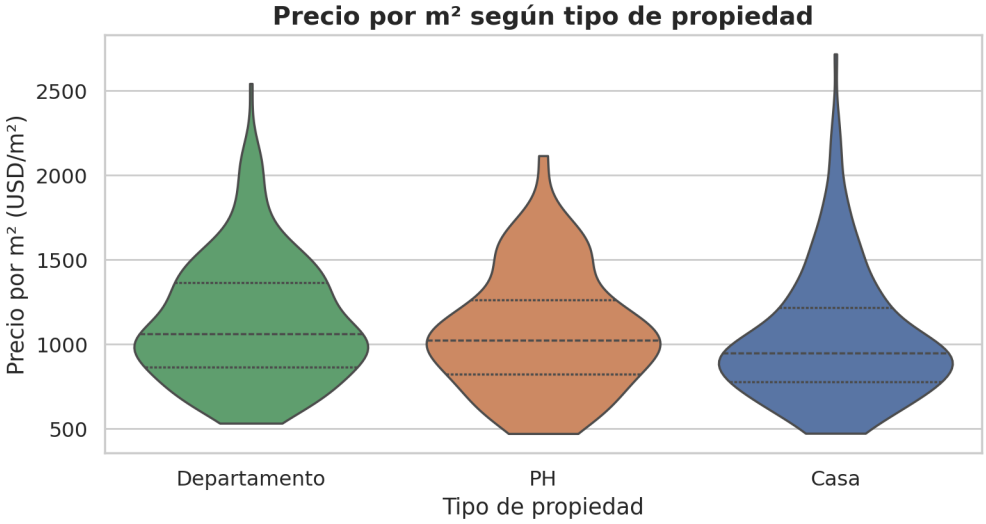
Qué observamos: Hay una relación **positiva y casi lineal**: a más m², más precio (Pearson r = 0,88; Spearman ρ = 0,82). Las casas se ubican a la derecha (más superficie) y los departamentos concentran los puntos de menor tamaño. Los puntos aislados de más de 350 m² están entre los outliers del gráfico 1: al excluir los 35 outliers de precio, r baja a 0,79, es decir que **los valores extremos inflan parcialmente la correlación**. **Conclusión:** la superficie será un predictor central, pero hay que tratar los outliers.

Gráfico 5 · Matriz de correlación



Qué observamos: El precio se asocia fuerte con la superficie (0,88) y moderadamente con los ambientes (0,62); con antigüedad (-0,16) y distancia al centro (-0,16) la relación lineal es débil y negativa. Superficie y ambientes están muy correlacionadas entre sí (0,86), por lo que son **casi redundantes**. **Conclusión:** al modelar conviene elegir una de las dos; y el peso de la superficie puede estar tapando el efecto de la ubicación, que sí se ve en el gráfico 3.

Gráfico 6 · Precio por m² según tipo de propiedad



Qué observamos: Al comparar el precio por m² (que elimina el efecto del tamaño) los tipos quedan más parecidos: mediana de USD 1.060/m² en departamentos, USD 1.022/m² en PH y USD 946/m² en casas. Las tres distribuciones son anchas y se superponen mucho, así que el tipo explica poco por sí solo; el PH tiene menos casos (n = 67) y su forma es menos confiable. **Conclusión:** el precio por m² depende más de la ubicación (gráfico 3) que del tipo de propiedad.

3. Hallazgos y próximos pasos

- **El precio está sesgado y tiene outliers** (35 casos por encima de USD 223.438). Se evaluará escala logarítmica y un tratamiento explícito de las propiedades premium.
- **Superficie y barrio** son las variables que más ordenan el precio; **ambientes** aporta poco una vez que se conoce la superficie (r = 0,86).
- **Tipo de propiedad** casi no diferencia el precio por m²; su valor está en la superficie que arrastra.
- **Próximos pasos:** estudiar la relación precio por m² vs distancia al centro, comparar modelos con y sin outliers y codificar el barrio como variable categórica.